

杜省严

Agent 开发工程师

dushenyan88@gmail.com · 18379514819 · 微信 Sy508080 · 海南 海口

自我描述

近 2 年聚焦 AI Agent 与 LLM 应用开发，在政务业务场景主导 3 个 AI 应用从 0 到 1 上线（智能客服知识中台 / GraphRAG 知识库 / LangGraph 多 Agent 研究助手）；5 年前端工程底蕴作为直接资产，对话工作台、流式渲染与过程可视化可独立完成，能把 Agent 从 Demo 推进到可交付产品。

核心优势：

• Agent 与编排：LangGraph 有向图状态机编排四角色 Agent（Checkpointer 断点续跑、控制流与语言任务分离）；Coze/Dify 低代码交付 8+ 业务智能体，双轨覆盖技术与场景

• RAG 与检索：GraphRAG 三存储异构架构、BM25 + 向量 RRF 融合检索、bge-reranker 两阶段精排、RAGAS 评估与 HITL 反馈闭环，Top-5 召回率 71% 提升至 93%

• 模型与底层：Qwen2.5 LoRA 微调（loss mask / ChatML / QLoRA）、意图识别四方案选型（BERT 方案 95%+ 准确率）、bge 向量与重排模型自适应部署

• 服务与部署：Python / FastAPI 异步全栈（MySQL / ES / Redis / Neo4j），Docker + XInference（vLLM 推理后端）+ AutoDL 私有化链路，数据不出域

项目经历

政务服务智能客服知识中台

角色：项目负责人（独立承担方案设计与后端核心开发）

基于 Python + FastAPI + Elasticsearch 8.x + SQLAlchemy 2.0 + Redis + Streamlit 开发

公司在承接政务服务数字化项目中，热线咨询与自助查询的 FAQ 知识分散在各业务线、口径不一且上线无灰度手段；据此主导建设统一知识中台，面向政务热线坐席、IM 客服助手与移动 App / Web 自助查询三类入口，由一套后端同时支撑知识生产、融合检索与多渠道问答；通过测试/正式双环境隔离发布让知识上线前可验证、可回滚

主要职责：

- 【融合检索】依托 Elasticsearch 8.x 单索引单分片架构，通过 Script Score / RRF 算法融合 BM25 全文检索与 dense_vector 语义向量检索，结合 Sentence-Transformers 本地化高性能推理，实现毫秒级高精度双路召回（P99 < 200ms，Top-5 命中率 92%）；调优层面以单分片规避多分片分数归并开销，RRF 按排名融合规避 BM25 与向量分数不可比问题，本地推理规避远程 API 网络往返
- 【多级缓存】设计 7 类业务缓存（类目树 / FAQ 详情 / 答案视角 / 搜索结果 / 渠道配置 / 热门 FAQ / 导航目录），按访问特征设置 5 分钟～24 小时差异化 TTL，配合缓存装饰器与写操作主动失效，解决「改了知识但线上还是旧答案」的一致性问题
- 【双环境发布】设计「测试环境配置、模拟验证、发布中心一键同步、正式环境生效」机制，用 env 字段隔离 + original_id 溯源使正式记录指向来源测试记录，让知识上线前可验证、可回滚
- 【多渠道答案适配引擎】抽象多视角答案适配引擎，支持按微信、App、Web 等渠道动态下发文本、富文本与交互卡片，同一问题在不同渠道返回差异化答案；预留标准化钉钉/企微 Webhook 接入层，问答能力经统一消息协议无缝嵌入多 IM 业务生态，新渠道接入不改动问答核心链路
- 【高并发工程吞吐】基于 FastAPI 异步并发框架构建全异步服务链路，SSE 流式响应驱动打字机式交互体验；按 routers / schemas / models / services 分层组织代码，优化 SQLAlchemy 2.0 批量处理链路，支撑 5 万级条目高效导出与 3000 条大文件异步批量导入

政务 RAG 知识库系统

角色：AI 应用负责人（方案设计与核心链路开发）

基于 Python + FastAPI + Elasticsearch + Neo4j + Sentence-Transformers + bge-reranker + RAGAS 开发

政务政策文件彼此引用关联、群众咨询常需跨文档多跳推理，通用 RAG 在此场景幻觉率高、回答无法溯源到政策原文即不可用；据此打造面向复杂政务场景的 GraphRAG 智能底座，显著压降大模型在政务政策多跳推理中的幻觉率，兼顾高召回率、低计算成本与强可解释性溯源，覆盖「文档解析、重叠分块、向量化、召回、精排、生成」全链路

主要职责：

- 【三存储异构架构】设计「MySQL（业务元数据）+ Elasticsearch（全文与向量双路）+ Neo4j（政务实体关系图谱）」的异构三存储架构，针对政务场景错综复杂的政策关联与多跳问答需求，通过图文协同检索打通跨文档隐式关联——图谱路径是政策条文联引、上下游修订关系等多跳推理的唯一可靠入口，补齐纯向量检索在语义相似度之外的推理盲区，具备不可替代性
- 【两阶段检索 + Rerank 工程权衡】混合检索召回 + bge-reranker-base 精排：以 BERT 分类模型对 (query, chunk) 对打分，召回阶段求快、精排阶段求准；并按业务场景决定 Rerank 引入时机——政策答复等高精度场景强制精排提升 Top-5 命中率，通用对话场景仅做混合检索以控制延迟与算力成本
- 【评估与反馈闭环】以 RAGAS 构建评估集对 faithfulness / answer relevancy / context precision 做版本化回归，配合 HITL 人机协同反馈（采纳 / 纠错 / 追问标注回流）驱动分块与精排策略迭代，上线一版回归后 faithfulness ≥ 0.92、Top-5 召回率由 71% 提升至 93%，让「召回质量调优」可量化、可归因
- 【可解释溯源闭环】采用 pdfplumber 结合重叠窗口进行版面智能分块，在 Chunk 元数据中持久化记录页码、关联图表路径，为前端「大模型回答精准溯源至原始政务图表」提供标准接口，形成企业级可解释性与溯源闭环
- 【模型服务化与私有化合规】embedding / rerank 模型在服务启动时加载一次并以模块级全局实例共享，避免每请求重复加载数 GB 权重带来的内存与耗时开销，支持 cuda / mps / cpu 自适应部署；生成侧大模型经 XInference（vLLM 推理后端）服务化接入，全链路私有化部署满足政务「数据不出域」的合规与安全要求

多 Agent 深度研究助手

角色：独立设计与开发

基于 Python + FastAPI + LangGraph + Redis + Jinja2 + Pydantic 开发

政务政策研究与需求调研依赖人工多轮检索整理，单主题耗时 2-3 小时且过程不可回溯；输入研究主题即自动完成多轮迭代调研，产出带来源引用、置信度标注与过程记录的结构化报告，把单主题调研压缩到 8-15 分钟

主要职责：

- 【Agent 编排】基于 LangGraph 有向图状态机编排 Keyword / Summary / Judge / Report 四角色分工，复用大厂主流工程框架的内置 Checkpointer 机制实现多轮长任务状态持久化与断点续跑，确保控制流确定性、可测试、可复现，语言任务完全下沉至 Agent 节点，避免自研编排框架的维护负担
- 【迭代收敛】每轮由 JudgeAgent 判断信息是否充分，不足则基于新关键词进入下一轮检索，以 max_rounds 上限保证收敛；单次检索失败兜底为空结果而不中断整体流程
- 【结构化与会话隔离】依托 Pydantic 与结构化输出自约束模式（schema 注入 function calling 约束 + 解析后二次校验、失败自动修复重试），将大模型格式解析失败率压降至 0.1% 以下；基于 FastAPI + Redis 实现多用户 session 级上下文隔离与会话 TTL 动态内存回收，确保高并发下多租户上下文零污染
- 【过程可审计】通过 LangGraph 状态快照与 on_progress 回调逐轮记录中间状态（步骤 / 草稿 / 来源），研究过程可落盘、可回放、可断点恢复；来源按 URL 去重，置信度基于来源时间分布确定性计算，无来源结论显式标注为模型推断
- 【上下文工程】采用 Jinja2 模块化模板集中管理 5 类 Agent 提示词，实现提示词资产版本化（git diff 可读）与控制流完全解耦，支持热更新与按角色独立灰度调优（A/B 不阻塞主流程），大幅降低复杂多智能体系统的提示词维护成本

MCP 工具服务器集合

角色：独立设计与开发

基于 Python + FastAPI + SQLite + Docker 开发

LLM 应用需要标准化的工具接入协议，而文件 / 数据库 / 企业 API 暴露给模型必须安全可控；据此实现 3 个 MCP（Model Context Protocol）服务器，采用「HTTP JSON-RPC 传输层 → MCP 协议核心 → 业务 Server」三层架构，覆盖协议握手、三原语注册与四道安全防线

主要职责：

- 【协议核心自研】自研轻量 mcp_core.py，实现 JSON-RPC 2.0 分发 + initialize 能力协商 + 结构化错误码体系（-32001 越权 / -32011 SQL 守卫 / -32602 参数错误），响应层永不抛异常，错误码按业务安全 / 协议 / 内部分层支撑问题快速定位
- 【三原语完整实现】每个 Server 同时注册 tools（模型可调用的动作）、resources（URI 寻址的上下文数据）、prompts（预置提示词模板），initialize 返回 capabilities 能力声明，协议版本 2024-11-05

- 【文件系统 Server 安全】list_dir / read_file / write_file 三工具 + file:// 资源 + 目录分析 prompt；realpath 白名单防 ../ 目录穿越与软链逃逸，配合只读开关与 64KB 读取上限
- 【SQLite SQL 守卫】query 仅放行 SELECT，正则拦截 DROP / DELETE / UPDATE / INSERT / ALTER / CREATE / ATTACH 7 类危险关键字，fetchmany(100) 限制结果集规模
- 【企业网关凭证隔离】把内部 HR / 项目系统包装为 MCP 工具，下游 service-token 由网关代持注入，客户端永远接触不到内部凭证；传输层 X-API-Token 统一校验，无 token 返回 401
- 【四道防线与服务化】路径白名单、只读模式、SQL 守卫、Token 鉴权四道防线经 9 组安全回归用例（目录穿越 / 越权写 / 危险 SQL / 无凭证访问）全部拦截验证；经 FastAPI 暴露统一 MCP 端点，token / 白名单 / 只读开关均由环境变量注入，Docker 一键部署

DevOps 运维诊断 Agent

角色：独立设计与开发

基于 Python + FastAPI + ReAct + HITL 开发

线上故障排查依赖资深 SRE 人肉串联「指标-日志-变更」三类证据，响应慢且经验难沉淀；据此实现告警触发自动诊断的运维 Agent——查指标、检索日志、分析 K8s 事件、定位根因，ReAct 观察-假设-验证循环 + HITL 安全处置，把 SRE 经验沉淀为可回归的诊断能力

主要职责：

- 【全链路诊断流水线】编排「告警接入 → 证据采集 → ReAct 诊断 → 修复方案 + 风险评估 → HITL 安全处置 → 准确率评估」完整闭环，并渲染 Markdown 诊断报告
- 【告警风暴防护】P1-P3 分级映射 + 同源告警 300s 窗口去重 + 按服务聚合关联，一波 4 条告警收敛为 1 次诊断，避免重复取证与告警疲劳
- 【ReAct 诊断循环】观察（规则引擎 4 条阈值：CPU>85% / 5xx>5% / DB P99>500ms / 连接池满，从海量证据过滤噪声）→ 假设（历史案例库召回 + LLM）→ 验证（LLM 调度工具逐轮取证，上限 MAX_VERIFY_ROUNDS=3 防死循环）→ 结论，实测定位到具体变更 deploy-v-2.3.1
- 【HITL 安全处置】修复方案先经 LLM 风险评估，高危操作无确认一律拦截，模拟执行失败自动回滚；变更关联窗口 CHANGE_WINDOW_MIN=60min
- 【根因准确率评估】DiagnosisEvaluator 将诊断结论与事后标注根因对比打分，≥80 记命中，实测 92/100，支撑诊断质量可量化回归
- 【证据源适配层解耦】日志 / 指标 / K8s 事件 / 变更四类证据源统一采集接口定义，适配层可插拔对接 Prometheus / ELK / K8s API / CMDB 采集器；Mock 采集器注入「发布后连接池泄漏」确定性故障场景，诊断层零改动即可全链路离线回归

工作经验

- **海南流云科技有限公司** 技术负责人 2022.07 — 至今 | 海南海口

  负责政务数字化核心产品的架构设计与交付，主导团队从纯前端向「前端 + AI 应用」双轨能力转型：业务侧主导政务 RAG 知识库、智能客服知识中台等 AI 应用从 0 到 1 落地（详见项目经历），研发侧引入 AI 编码工具与 Skills/Rules 体系

  - 【AI 应用落地】面向政务业务场景主导三个 AI 应用的设计与交付：政务服务智能客服知识中台（ES 融合检索 + 多渠道答案适配）、政务 RAG 知识库（GraphRAG 三存储 + 两阶段检索 + RAGAS 评估）、多 Agent 深度研究助手（LangGraph 编排），上线后客服首答率达 80%+、单主题调研耗时从 2-3 小时压至 15 分钟内，把政务产品从表单办理升级到智能问答与辅助调研
  - 【智能体平台交付】基于 Coze / Dify 低代码平台交付政策咨询、材料预审等 8+ 业务智能体，经钉钉发布给坐席与公众侧使用，与自研 Agent 形成「低代码快速覆盖 + 自研攻坚深水区」双轨节奏
  - 【AI 研发效能】在项目中引入 Cursor / Trae 等 AI 编码工具，沉淀 Agent Skills 与自定义 Rules 约束 AI 生成代码的规范与边界，统一项目初始化流程与代码风格
  - 【架构与工程化】主导 Vue2 至 Vue3 + TS 技术栈升级并建立统一组件库，开发效率提升 50%；自研脚手架统一项目初始化流程，为后续 AI 应用集成统一脚手架基线
  - 【团队建设】带领 5 人团队，建立 Code Review 与自动化测试流程，代码质量问题减少 60%；牵头团队每周 AI 技术分享，推动团队整体向 AI 应用方向转型

- **江西蓝源科技有限公司** 前端开发工程师 / 技术骨干 2021.07 — 2022.07 | 江西南昌

  负责公司核心产品的前端开发与性能优化，场景覆盖管理后台、数据大屏与多端应用，参与技术方案设计与评审，推动工程规范建设

  - 【数据可视化】优化大型数据可视化组件，以 Canvas 替代 SVG，数据渲染速度提升 200%；主导大数据可视化平台前端建设，基于 Three.js + ECharts 实现 3D 地图交互与多图表联动，设计 vw 适配方案支持大屏/小屏双模式展示
  - 【跨端开发】基于 uni-app 实现微信小程序 + H5 一套代码多端交付，沉淀字典数据、列表分页等跨端复用方案，解决 iOS 安全区适配等端侧兼容问题
  - 【首屏性能】通过路由懒加载、组件按需引入与静态资源缓存策略优化管理后台首屏加载，首屏渲染耗时降低 40%
  - 【规范建设】建立前端开发规范与代码评审流程，推动 ESLint + Prettier 统一代码风格

个人项目

AI 文件整理助手

基于 TypeScript + Node.js + MCP + commander + zod 开发

独立设计与实现：按规则或 AI 语义对文件分类、重命名，AI 侧打通「提供商客户端—MCP 工具调用—批量调度」完整链路

主要职责：

- 【MCP 客户端自研】以 JSON-RPC 2.0 over stdio 手写 MCP 协议层：initialize 握手与能力协商、tools/list 发现与 tools/call 调用、MCP server 进程（如 filesystem server）的拉起与生命周期管理，不依赖重型 SDK，协议细节可控可调
- 【多提供商统一抽象】设计 Gemini / DeepSeek / Qwen 等多家提供商的统一客户端接口：基类抽象 + 配置化模型参数，切换提供商只需改一行 YAML，密钥全走环境变量零明文
- 【规则分类引擎】按扩展名 / 日期 / 大小 / 名称多维规则分类，叠加 AI 语义分类与重命名并结合文件内容分析提升归类准确度，原生支持中文文件名；配置文件维护排除（ignore）模式精准筛选待处理文件
- 【AI 调用成本与安全】批量处理管线合并文件元数据减少 AI 调用次数以适配免费层限流；dry-run 模拟执行先验后动，配合目录级自定义提示词，解决「AI 误操作不可回滚」与「命名风格不可控」两个落地问题
- 【CLI 工程底座】commander + @clack/prompts 双交互模式（命令行 / 向导式），chalk / fs-extra / yaml 支撑终端输出与文件操作，tsdown 打包输出 CLI 与类型声明，vitest 单测保障重构安全网
- 【可配置调优项】提供商 / 模型、批量大小与限流、dry-run 与 verbose 开关、目录级自定义提示词、系统 / 手动代理双通道均可经 YAML 配置，改一行即切换后端；-V 版本显示、子命令自定义帮助与 bumpp 一键发布收敛日常操作

基于AutoDL端 Qwen微调 LoRA 实战

基于 Python + PEFT / LoRA + transformers + QLoRA 开发

主要职责：

- 【数据准备与格式对齐】整理指令数据集并转成 ChatML 对话格式，用 loss mask 只对 assistant 回复段计算损失，避免 prompt 部分污染训练信号
- 【LoRA 训练配置】基于 PEFT 注入低秩适配器（仅约 0.4% 参数可训练），对比 rank / alpha / dropout 与目标模块（q_proj / v_proj 等）对收敛与显存的影响，在消费级单卡跑通 Qwen2.5-Instruct 微调
- 【训练与推理解码一致性】严格区分训练拼接格式与推理 generate 模板，配置双停止符（EOS + 自定义 stop token）防越界续写，调优 temperature / top_p 平衡稳定性与多样性
- 【QLoRA 资源优化】掌握 QLoRA 4bit 量化 + LoRA 组合在显存受限时如何进一步压缩，理解 offline / online 量化与 paged optimizer 的取舍

专业技能

Agent 与 LLM 应用	多 Agent 编排与角色分工 · Few-shot 动态样本检索 · LangGraph / AutoGen 多智能体框架 · 结构化输出与 OutputParser · Function Calling / Tool Use / ReAct 诊断循环 · MCP（Model Context Protocol，JSON-RPC 2.0 协议层） · 多租户上下文隔离与会话管理 · 工具调用安全防线（路径白名单 / SQL 守卫 / 凭证隔离） · Prompt Engineering（Jinja2 模板化）
RAG 与语义检索	混合检索（BM25 + dense_vector / RRF 融合） · Milvus 向量库租户分区 · 中文向量模型（bge-small / base-zh） · 重排序（bge-reranker） · 文档解析与重叠分块策略 · 语义拆分 / 递归拆分对比 · 召回质量评估与调优（RAGAS） · HITL 人机协同反馈闭环
智能体平台（Coze / Dify）	Coze 工作流编排与代码节点 · Dify 应用发布与 API 化 · SSE 流式响应处理 · 钉钉 / 企微 IM 渠道集成 · 官方模板复用与二次开发
LangChain 全栈	LCEL 链式编排（prompt | model | parser） · ChatPromptTemplate / FewShot 模板 · Memory 四策略（Buffer / Window / Token / Summary） · @tool / StructuredTool / bind_tools · create_tool_calling_agent + AgentExecutor · Chroma / Elasticsearch 向量库双栈 · RunnableWithMessageHistory 多会话隔离
模型微调与推理	LoRA / QLoRA 微调（PEFT） · loss mask 与 ChatML 格式对齐 · 双停止符与生成参数调优 · 意图识别多方案选型 · Sentence-Transformers 语义向量 · transformers / PEFT / accelerate · vLLM / SGLang 推理加速与服务化部署 · ChatOllama 本地模型接入
深度学习与 NLP 基础	反向传播（链式法则手推） · BatchNorm / Dropout / L2 正则 · RNN / LSTM / GRU 与序列建模 · Transformer（Self-Attention / 多头 / 位置编码） · BERT / GPT 与 bert-base-chinese 微调 · jieba 分词 / Word2Vec / Gensim · Hugging Face transformers / datasets
服务端与存储	Python / FastAPI（ASGI 异步） · MySQL + SQLAlchemy 2.0（aiomysql） · Elasticsearch 8.x（全文 + 向量） · Redis 多级缓存与主动失效 · Neo4j 知识图谱 · TypeScript / Node.js
私有化部署与运维	Docker / Docker Compose · Coze Studio 开源部署 · Linux 容器化环境 · XInference（vLLM 推理后端，LLM / Embedding / Rerank 一站式部署） · AutoDL GPU 租赁与按需算力
Agent 前端工程	对话工作台与流式渲染 · 工具调用过程可视化 · Vue 3 / React · 会话状态管理与持久化
工程化与 AI 研发效能	uv / Makefile · Monorepo（pnpm workspace） · ESLint / Husky · CI/CD 与 Docker 部署 · Agent Skills 编写 · 自定义 Rules / Command · Claude Code / Trae · AI 辅助研发流程设计

教育经历

- **江西交通职业技术学院 信息工程系 计算机网络技术** 2018.09 至 2021.06
  主修课程：计算机网络、Web前端开发、数据库原理、软件工程等
  计算机网络 · 数据库原理 · Web前端开发 · 软件工程
- **大模型应用体系 深度学习 · NLP · LangChain · 智能体工程** 2024.01 至 至今 | 体系化学习
  按「底层原理、工程框架、平台交付」三阶系统补齐大模型应用链路

荣誉奖项

- **海南省数据应用创新奖** 海南省大数据管理局（海南营商数据大屏项目） 2023-10
- **公司年度优秀技术负责人** 海南流云科技有限公司（技术创新与团队建设突出） 2024-01