



杜审言

Agent 开发工程师

邮箱: shenyandu@qq.com · 电话: 18379514819 · 微信: Sy508080 · 海南 海口

自我描述



前端工程师出身，近 8 年工程经验；近 2 年系统转向 AI Agent 与 LLM 应用开发，个人项目覆盖「模型微调、语义检索、RAG、多 Agent 编排」完整链路。

核心优势：

- Agent 与编排：自研四角色 Agent 编排器（控制流与语言任务分离）、Coze/Dify 低代码平台 8+ 业务智能体交付、LangChain 全栈（LCEL / Memory / Tools / RAG）
- RAG 与模型：三存储 RAG 架构、BM25 + 向量混合检索 + bge-reranker 精排两阶段管线、Qwen2.5 LoRA 微调、bge 中文向量与重排模型自适应部署
- 服务与部署：Python / FastAPI 异步全栈（MySQL / ES / Redis / Neo4j），Docker + XInference + AutoDL 私有化部署链路

项目经历

FAQ 智能问答平台



基于 Python + FastAPI + Elasticsearch 8.x + SQLAlchemy 2.0 + Redis + Streamlit 开发

主要职责：

- 【混合检索】在 Elasticsearch 单索引内同时建立 BM25 全文与 dense_vector 向量字段，用 Sentence-Transformers 本地生成向量，实现关键词与语义双路召回
- 【多级缓存】设计 7 类业务缓存（类目树 / FAQ 详情 / 答案视角 / 搜索结果 / 渠道配置 / 热门 FAQ / 导航目录），按访问特征设置 5 分钟~24 小时差异化 TTL，配合缓存装饰器与写操作主动失效，解决「改了知识但线上还是旧答案」的一致性问题
- 【双环境发布】设计「测试环境配置、模拟验证、发布中心一键同步、正式环境生效」机制，用 env 字段隔离 + original_id 溯源使正式记录指向来源测试记录，让知识上线前可验证、可回滚
- 【多视角答案】同一问题按微信 / App / 网页渠道返回差异化答案，答案类型支持纯文本、富文本与交互式卡片，覆盖 15+ 个管理端与对外服务接口
- 【流式与 IM 渠道】对外服务接口支持 SSE 流式响应以驱动前端打字机式体验；预留钉钉 / 企微机器人对接入口，把问答能力推到 IM 业务渠道
- 【工程质量】按 routers / schemas / models / services 分层，覆盖管理端与对外服务；支持 3000 条批量导入与 50000 条导出

政务 RAG 知识库系统



基于 Python + FastAPI + Elasticsearch 8.x + Neo4j + Sentence-Transformers + bge-reranker 开发

主要职责：

- 【三存储架构】MySQL 存知识库与文档元信息、Elasticsearch 存 chunk 全文与 embedding_vector，Neo4j 承载实体关系图谱，按查询特征为三类存储分工，为多跳问答留出入口
- 【两阶段检索】混合检索召回 + bge-reranker-base 精排：以 BERT 分类模型对 (query, chunk) 对打分，召回阶段求快、精排阶段求准，解决单纯向量召回精度不足的问题
- 【Rerank 工程权衡】按业务场景决定 Rerank 引入时机——专业库 / 客服等高精度场景强制走精排以提升 Top-5 命中率，通用对话场景仅做混合检索以控制延迟与算力成本
- 【模型服务化】embedding / rerank 模型在服务启动时加载一次并以模块级全局实例共享，避免每请求重复加载数 GB 权重带来的内存与耗时开销；支持 cuda / mps / cpu 自适应部署
- 【分块与多模态预留】PDF 经 pdfplumber 解析后按重叠窗口分块，chunk 表同时记录页码、关联图片与关联表格路径，为「回答引用原文图表」预留接口

多 Agent 深度研究助手



基于 Python + FastAPI + 多 Agent 编排 + Jinja2 + Web Search 开发

主要职责：

- 【Agent 编排】设计 KeywordAgent / SummaryAgent / JudgeAgent / ReportAgent 四角色分工，编排器只做确定性控制流、不发起任何 LLM 调用，让流程可测试、可复现，语言任务完全下沉到 Agent
- 【迭代收敛】每轮由 JudgeAgent 判断信息是否充分，不足则基于新关键词进入下一轮检索，以 max_rounds 上限保证收敛；单次检索失败兜底为空结果而不中断整体流程
- 【结构化与会话隔离】Judge / Report 输出采用 JSON schema + format_instructions 自约束模式（对标 OutputParser）将格式失败率压到可忽略；多用户会话按 session_id 隔离存储，互不污染上下文
- 【过程可审计】通过 on_progress 回调逐轮快照中间状态（步骤 / 草稿 / 来源），研究过程可落盘、可回放；来源按 URL 去重，置信度基于来源时间分布确定性计算，无来源结论显式标注为模型推断
- 【Prompt 工程】以 Jinja2 模板集中管理 keyword / summary / judge / report 等 5 类提示词，便于独立迭代调优而不改控制流代码

意图识别服务

基于 Python + FastAPI  transformers + scikit-learn 开发

工作经验

海南流云科技有限公司 前端开发工程师 / 技术负责人 

2022.07 - 至今 | 海南海口

负责政务数字化核心产品的架构设计与交付，主导团队从纯前端向「前端 + AI 应用」双轨能力转型：业务侧落地知识库与智能检索产品，研发侧引入 AI 编码工具与 Skills/Rules 体系

- 【AI 研发效能】在项目中引入 Cursor / Trae 等 AI 编码工具，沉淀 Agent Skills 与自定义 Rules 约束 AI 生成代码的规范与边界，统一项目初始化流程与代码风格
- 【架构与工程化】主导 Vue2 至 Vue3 + TS 技术栈升级并建立统一组件库 (liuyun-ui)，开发效率提升 50%；自研 liuyun-cli 脚手架统一项目初始化流程，为后续 AI 应用集成统一脚手架基线
- 【团队建设】带领 5 人前端团队，建立 Code Review 与自动化测试流程，代码质量问题减少 60%；牵头团队每周 AI 技术分享，推动团队整体向 AI 应用方向转型

江西蓝源科技有限公司 前端开发工程师 / 技术骨干

2018.12 - 2022.07 | 江西南昌

负责公司核心产品的前端开发与性能优化，参与技术方案设计与评审，推动工程规范建设

- 【数据可视化】优化大型数据可视化组件，以 Canvas 替代 SVG，数据渲染速度提升 200%
- 【规范建设】建立前端开发规范与代码评审流程，推动 ESLint + Prettier 统一代码风格，输出 10+ 篇技术文档

个人项目

大模型 LoRA 微调实战 (fine-tuning)

Qwen2.5-Instruct LoRA 微调全流程：从理论到数据准备、训练、推理调优，掌握「仅微调约 0.4% 参数即可接近全量效果」的工程平衡；细节上严格区分训练与推理解码格式、双停止符配置，理解 QLoRA 量化方案在资源受限时如何进一步压缩

基于 Python + PEFT / LoRA + transformers + QLoRA 开发

统一 LLM 调用封装库 (sy-llm)

零运行时依赖的 LLM 统一封装：抽象基类支持 Ollama 本地 / DeepSeek 云端一键切换，同步异步双链路复用一份代码；密钥全走环境变量、业务代码零明文，配套标准 src-layout 包工程

基于 Python + 标准库 + Ollama 开发

BERT 原理实战 (bert-encoder)

BERT 原理系统实战：从 Token / Position / Segment 三层 Embedding 与自注意力机制可视化，到「冻结特征提取 vs 全参数微调」的对比，并完成中文六大任务迁移与变体模型选型 (RoBERTa / ALBERT / DistilBERT / ELECTRA)

基于 Python + transformers + PyTorch 开发

RNN 输入法候选词预测 (input-method-rnn)

用 vanilla RNN 模拟输入法候选词推荐：jieba 分词 + 词表构建 + 滑动窗口造样本，全管线（数据、训练、评估、推理）可独立运行；Top-1 准确率 0.21、Top-5 0.40

基于 Python + PyTorch + RNN 开发

搜索关键词推荐 (word2vec-recommend-key)

word2vec 词向量相似词扩展驱动搜索联想系统，工程完整度高：CLI 子命令（train / eval / recommend / check）+ 评测集与指标 + Web 演示，并记录历史输入做个性化推荐

基于 Python + word2vec + CLI 开发



专业技能

Agent 与 LLM 应用

- 多 Agent 编排与角色分工
- Function Calling / Tool Use
- 多轮会话与上下文管理
- MCP (Model Context Protocol)
- Prompt Engineering (Jinja2 模板化)
- Few-shot 动态样本检索
- 结构化输出与 OutputParser

智能体平台 (Coze / Dify)

- Coze 工作流编排与代码节点
- Dify 应用发布与 API 化
- SSE 流式响应处理
- 钉钉 / 企微 IM 渠道集成
- 官方模板复用与二次开发

模型微调与推理

- LoRA / QLoRA 微调 (PEFT)
- loss mask 与 ChatML 格式对齐
- 双停止符与生成参数调优
- 意图识别多方案选型
- Sentence-Transformers 语义向量
- transformers / PEFT / accelerate

服务端与存储

- Python / FastAPI (ASGI 异步)
- MySQL + SQLAlchemy 2.0 (aiomysql)
- Elasticsearch 8.x (全文 + 向量)
- Redis 多级缓存与主动失效
- Neo4j 知识图谱
- TypeScript / Node.js

Agent 前端工程

- 对话工作台与流式渲染
- 工具调用过程可视化
- Vue 3 / React
- 会话状态管理与持久化

AI 研发效能

- Agent Skills 编写
- 自定义 Rules / Command
- Claude Code / Trae
- AI 辅助研发流程设计

自我评价

✓ 系统补齐深度学习 / NLP / LangChain / 智能体工程四块体系，覆盖底层原理到工程落地的完整学习路径

RAG 与语义检索

- 混合检索 (BM25 + dense_vector)
- 中文向量模型 (bge-small / base-zh)
- 重排序 (bge-reranker)
- 文档解析与重叠分块策略
- 语义拆分 / 递归拆分对比
- 召回质量评估与调优

LangChain 全栈

- LCEL 链式编排 (prompt | model | parser)
- ChatPromptTemplate / FewShot 模板
- Memory 四策略 (Buffer / Window / Token / Summary)
- @tool / StructuredTool / bind_tools
- create_tool_calling_agent + AgentExecutor
- Chroma / Elasticsearch 向量库双栈
- RunnableWithMessageHistory 多会话隔离

深度学习与 NLP 基础

- 反向传播 (链式法则手推)
- BatchNorm / Dropout / L2 正则
- RNN / LSTM / GRU 与序列建模
- Transformer (Self-Attention / 多头 / 位置编码)
- BERT / GPT 与 bert-base-chinese 微调
- jieba 分词 / Word2Vec / Gensim
- Hugging Face transformers / datasets

私有化部署与运维

- Docker / Docker Compose
- XInference (LLM / Embedding / Rerank 一站式部署)
- AutoDL GPU 租赁与按需算力
- Coze Studio 开源部署
- Linux 容器化环境

工程化与交付

- uv / Makefile
- Monorepo (pnpm workspace)
- ESLint / Husky
- CI/CD 与 Docker 部署

- ✓ 「低代码 + 自研」双轨 Agent 能力：自研四角色编排器，也可基于 Coze/Dify 交付业务智能体；技术与场景两边都能上手
- ✓ RAG 工程链路：三存储架构、BM25 + 向量混合检索、bge-reranker 精排两阶段管线，理解「精度 vs 延迟」的工程权衡
- ✓ 模型侧动手能力：Qwen2.5 LoRA 微调（loss mask / ChatML / QLoRA）、意图识别多方案选型、bge 向量与重排模型自适应部署
- ✓ 近 8 年前端底蕴是直接资产：对话工作台、流式渲染与过程可视化由我补全，能把 Agent 原型推进到可交付而非停在 Demo

教育经历



江西交通职业技术学院 信息工程系 计算机网络技术

2018.09 至 2021.06 专科

主修课程：计算机网络、Web前端开发、数据库原理、软件工程等

计算机网络

数据库原理

Web前端开发

软件工程

大模型应用体系 深度学习 · NLP · LangChain · 智能体工程

2024.01 至 至今 体系化学习

按「底层原理、工程框架、平台交付」三阶系统补齐大模型应用链路

荣誉奖项

海南省数据应用创新奖 海南省大数据管理局（海南营商数据大屏项目）

2023-10

公司年度优秀技术负责人 海南流云科技有限公司（技术创新与团队建设突出）

2023-01-01